

Machine Learning para la detección de enfermedades

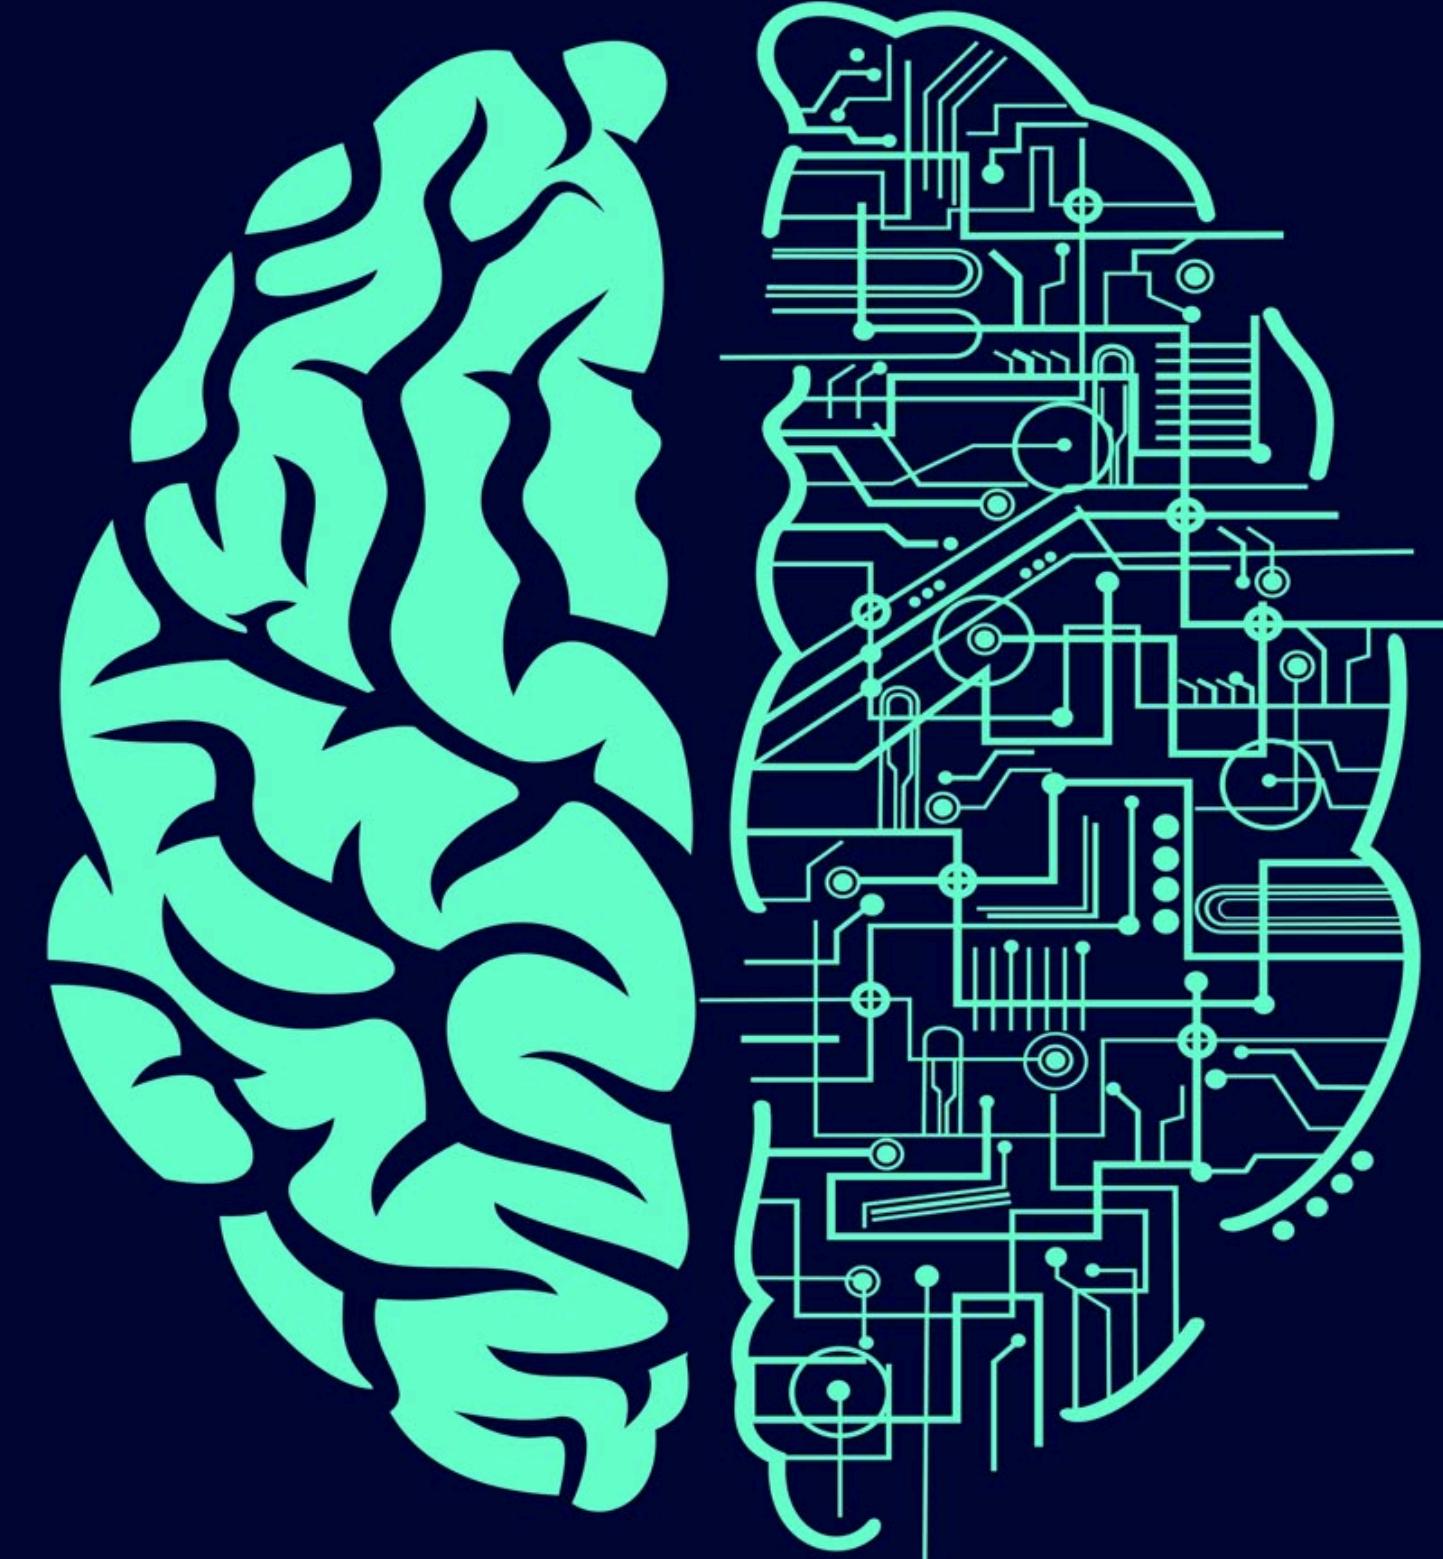
Abitia Burgos Julio Alejandro



¿QUE ES EL MACHINE LEARNING?

Machine learning es un campo de la inteligencia artificial que permite que los sistemas aprendan automáticamente a partir de datos, identifiquen patrones y realicen predicciones sin ser programados explícitamente.

(Jordan & Mitchell, 2015).



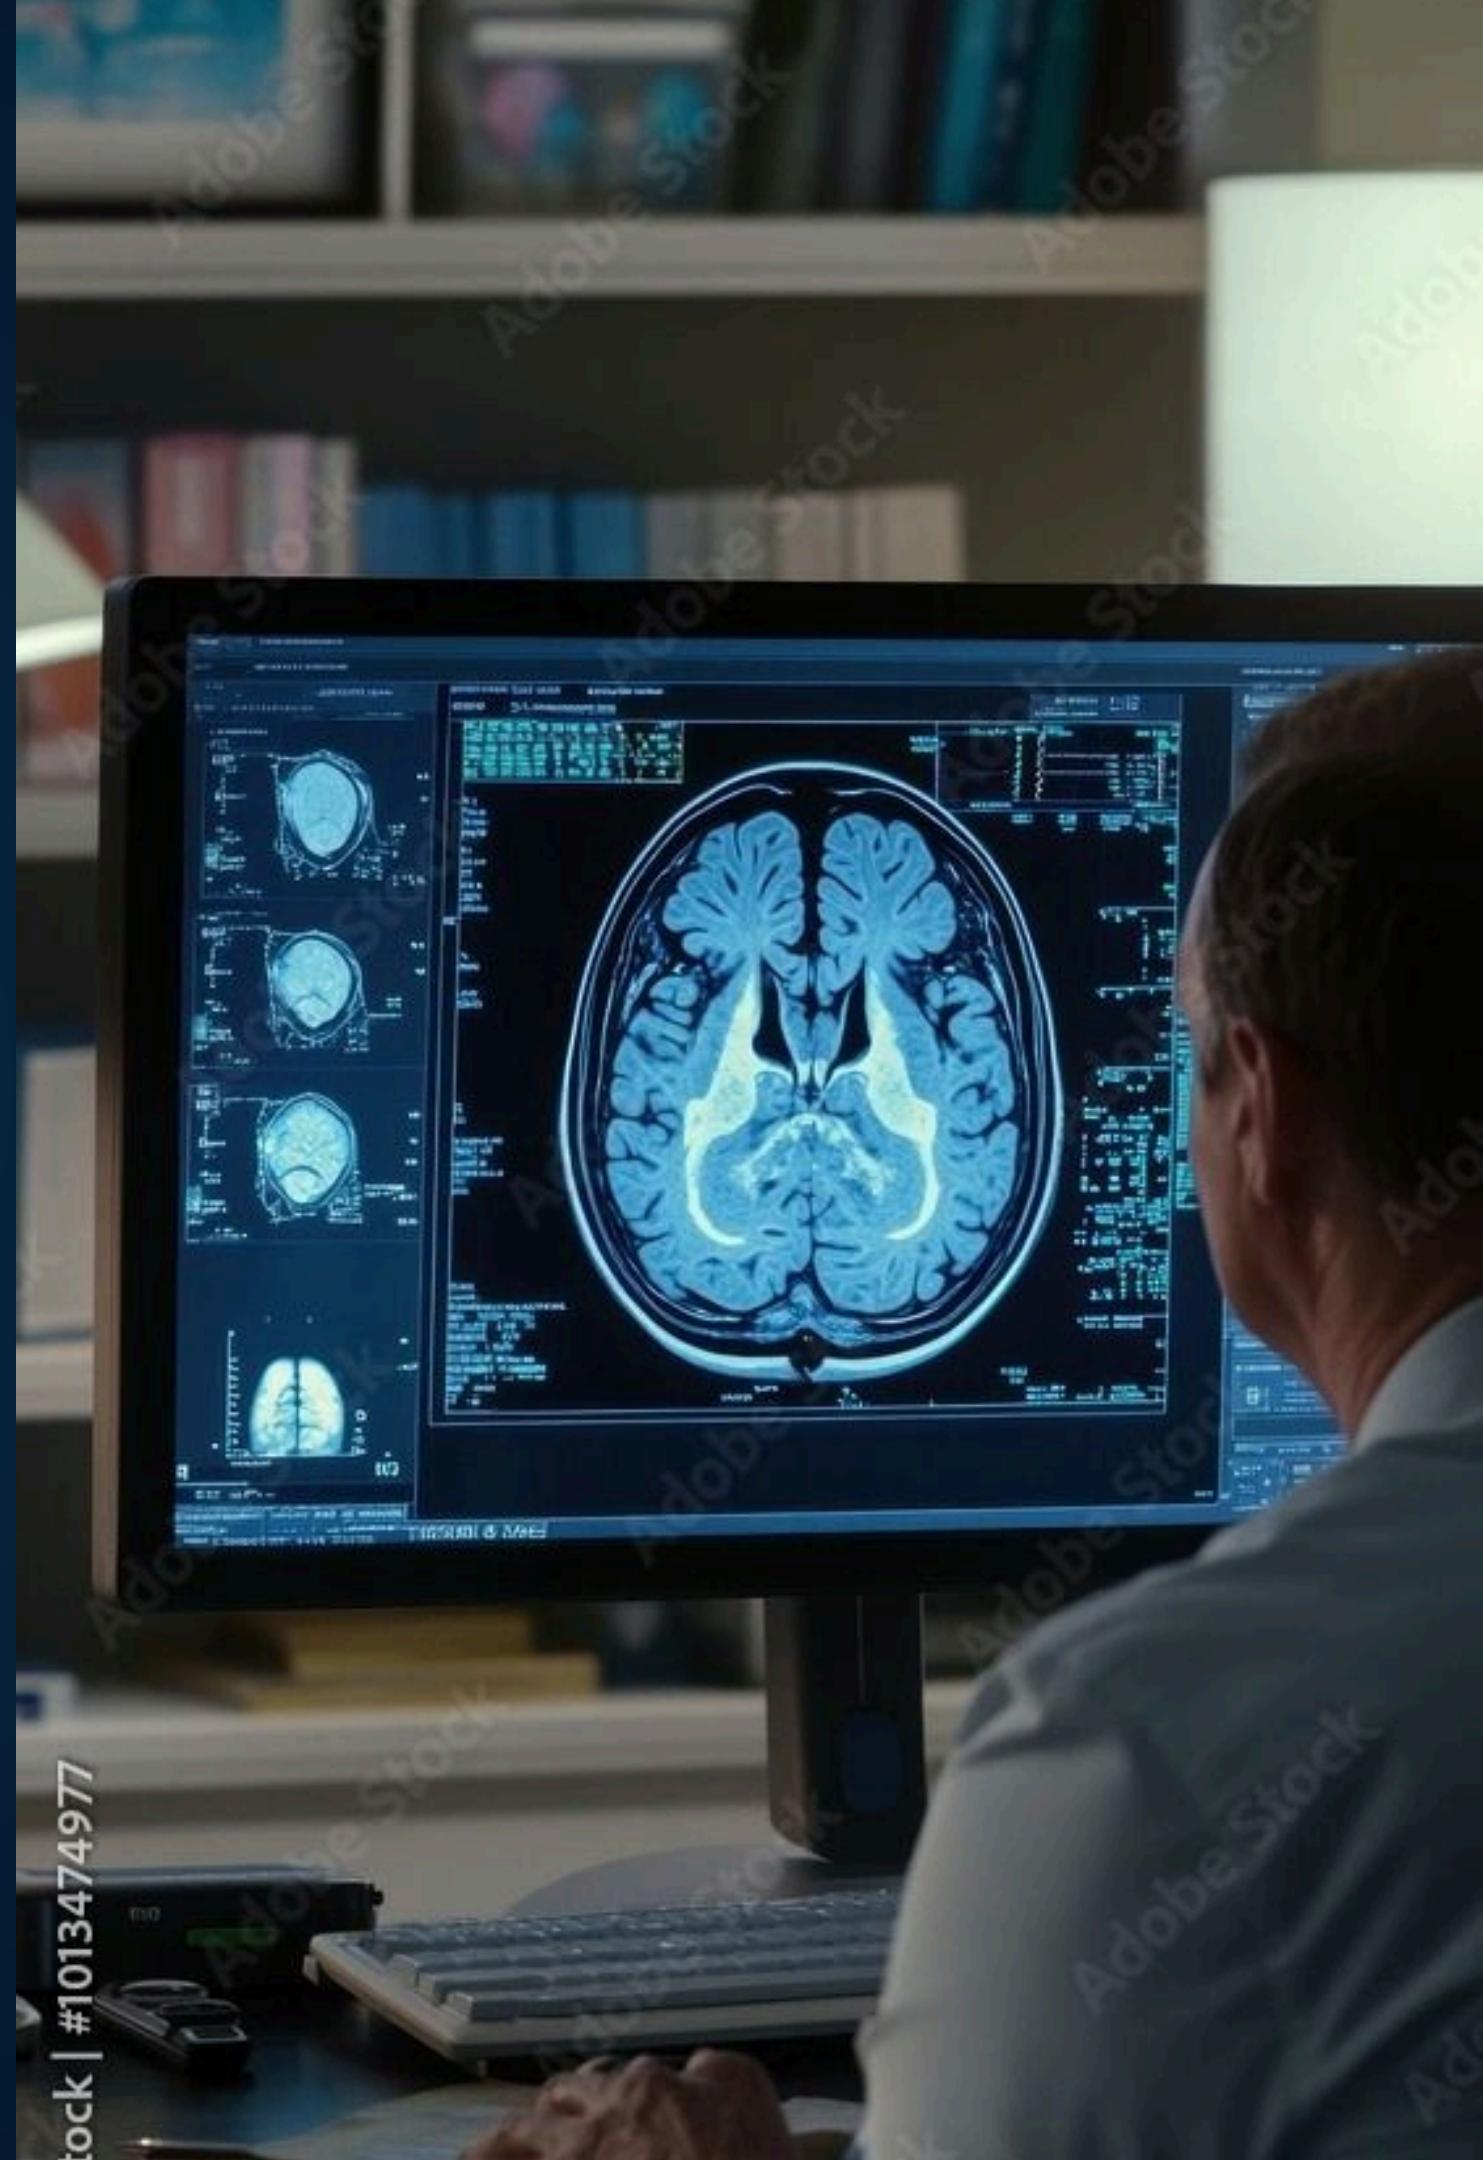
¿POR QUE MACHINE LEARNING ES IMPORTANTE EN LA MEDICINA?

Mejora la precisión diagnóstica al detectar patrones que los médicos no siempre pueden ver.

Permite diagnósticos más tempranos, lo cual aumenta las probabilidades de tratamiento exitoso.

Reduce errores humanos, actuando como una segunda opinión optimizada.

Analiza miles de imágenes o datos clínicos en segundos, acelerando la atención.



¿COMO FUNCIONA EL MACHINE LEARNING EN EL DIAGNOSTICO?

El Machine Learning (ML) funciona en el diagnóstico médico analizando grandes cantidades de datos –como imágenes, resultados clínicos, historial médico o señales fisiológicas– para identificar patrones que los humanos no pueden ver fácilmente.

El ML aprende de ejemplos previos para predecir si un paciente tiene una enfermedad o cuál es el riesgo de desarrollarla.



A) PROCESAMIENTO Y PREPARACION DE LOS DATOS

Antes de entrenar a un modelo , los datos medicos deben:

- Limpiarse, esto implica valores faltantes o duplicados.
- Normalizarse (ajustar escalas).
- Seleccionar características relevantes , como biomarcadores, edad, sintomas o patrones de imagen.

B) ENTRAMIENTO DEL MODELO

Hay tres enfoques principales para esto

- Aprendizaje supervisado:El modelo aprende a partir de datos con diagnóstico ya conocido. Es el más usado para detección de enfermedades
- No supervisado: El modelo identifica grupos o patrones sin etiquetas, útil para detectar subtipos desconocidos de enfermedades.
- Deep Learning: Modelos avanzados (redes neuronales) que aprenden características complejas en imágenes o señales.

C) EVALUACION DEL MODELO

El rendimiento del sistema se mide con:

- Sensibilidad (recall): Capacidad de detectar pacientes enfermos.
- Especificidad : Capacidad de identificar correctamente a los sanos.
- Precisión General: Clasificación del modelo

D) IMPLEMENTACION EN DIAGNOSTICO

Una vez validado el modelo puede:

- Detectar enfermedades de manera temprana.
- Predecir riesgos.
- Apoyar decisiones clínicas.
- Reducir diagnósticos tardíos o imprecisos.

MACHINE LEARNING APLICANDO A IMAGENES MEDICAS

El ML, especialmente el Deep Learning, tiene un impacto enorme en el análisis de imágenes como:

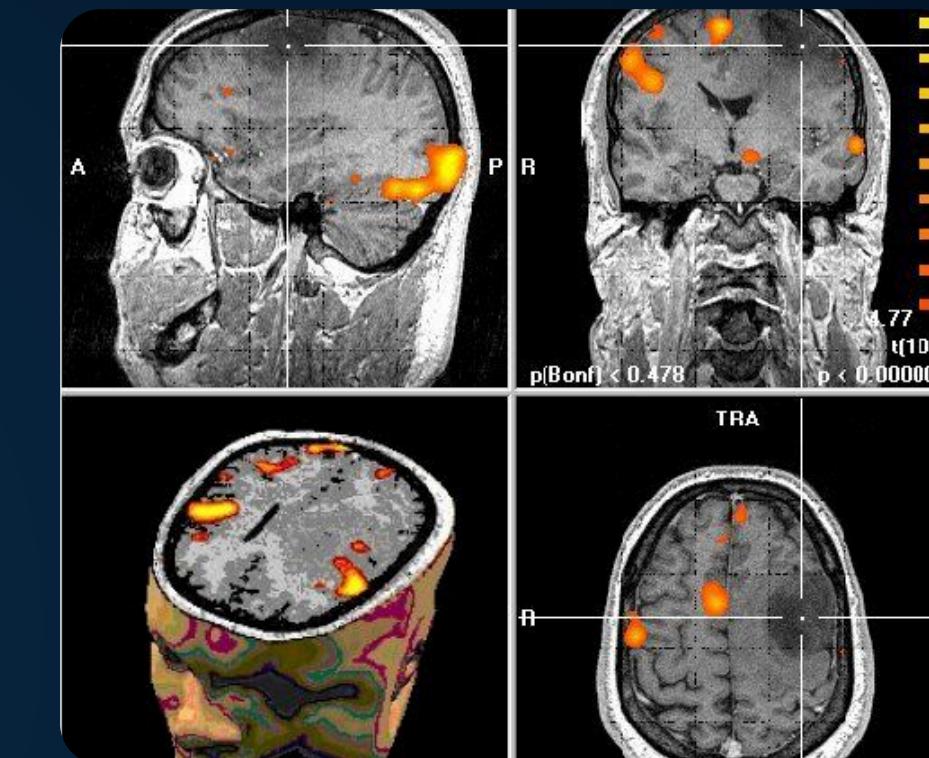
Radiografias



Tomografias



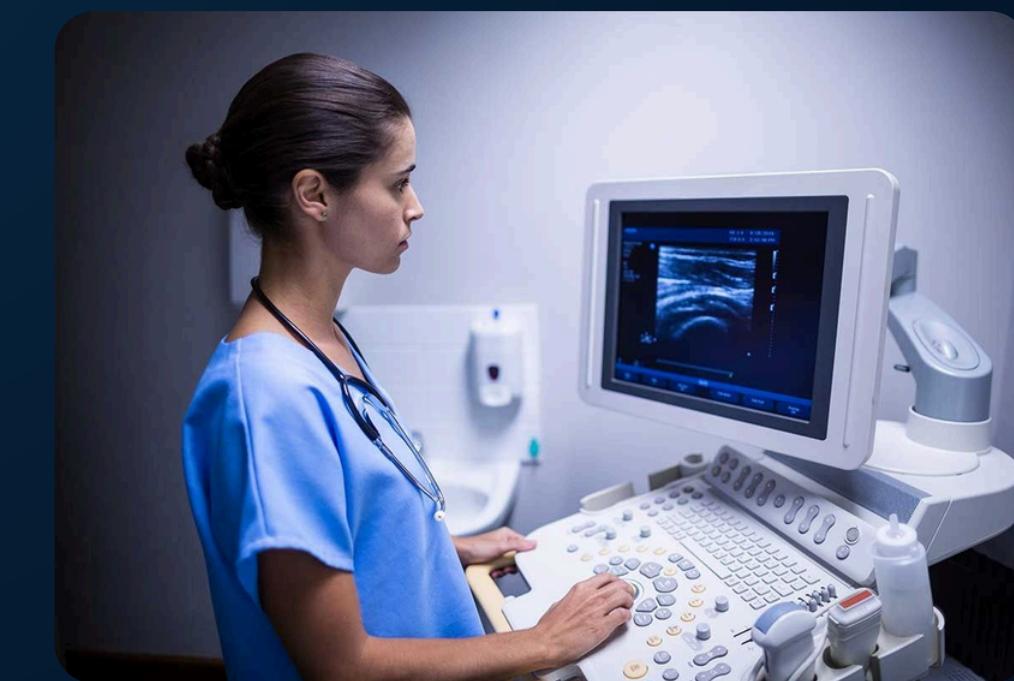
Resonancias Magneticas (MRI)



Mamografias



Ultrasonidos



¿COMO FUNCIONA?

- 1: Redes neuronales convolucionales (CNN) procesan la imagen por capas, detectando bordes, texturas, formas y estructuras internas.
- 2: El sistema aprende ejemplos de imágenes con y sin enfermedad.
- 3: El modelo predice si la imagen tiene signos de una patología.

APLICACIONES

- Detección temprana de cáncer (mama, pulmón, piel).
- Identificación de tumores.
- Detección de fracturas.
- Segmentación de órganos o lesiones.
- Clasificación de enfermedades pulmonares.

VENTAJAS

- Alta precision comparable a expertos
- Rapidez en interpretacion
- Ayuda a reducir diagnosticos tardios.

ML PARA DATOS CLINICOS

Laboratorios(glucosa,creatinina,
colesterol)

Historial Medico

Síntomas



COMO SE USA EL ML EN LOS DATOS CLINICOS

Los modelos aprenden patrones en combinaciones de datos clínicos para

Predecir enfermedades crónicas
(diabetes, insuficiencia cardíaca)

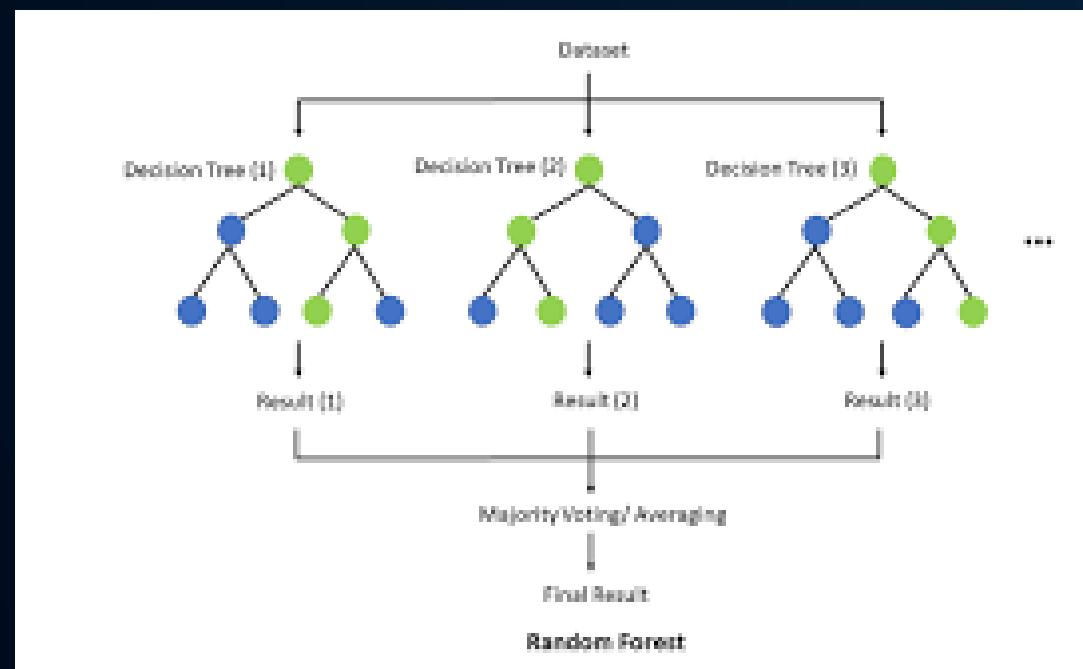
Identificar pacientes de alto riesgo

Calcular riesgo de mortalidad

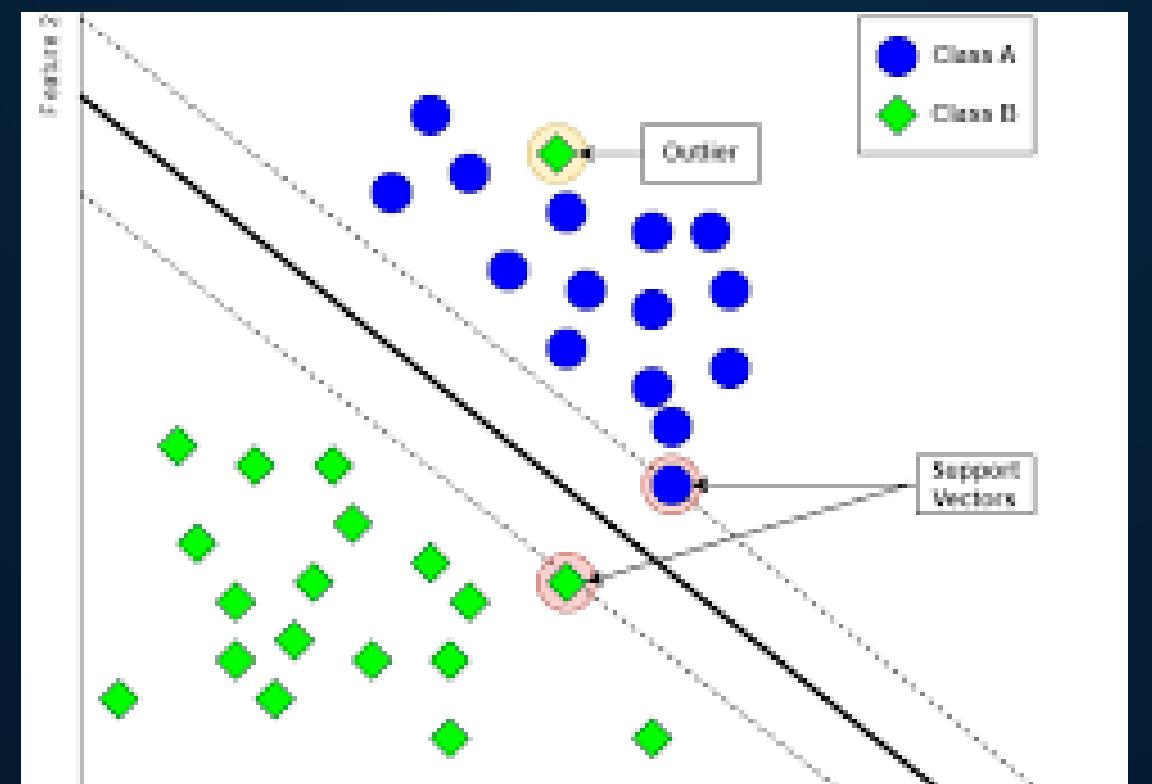
Optimizar tratamientos personalizados

Algoritmos más usados

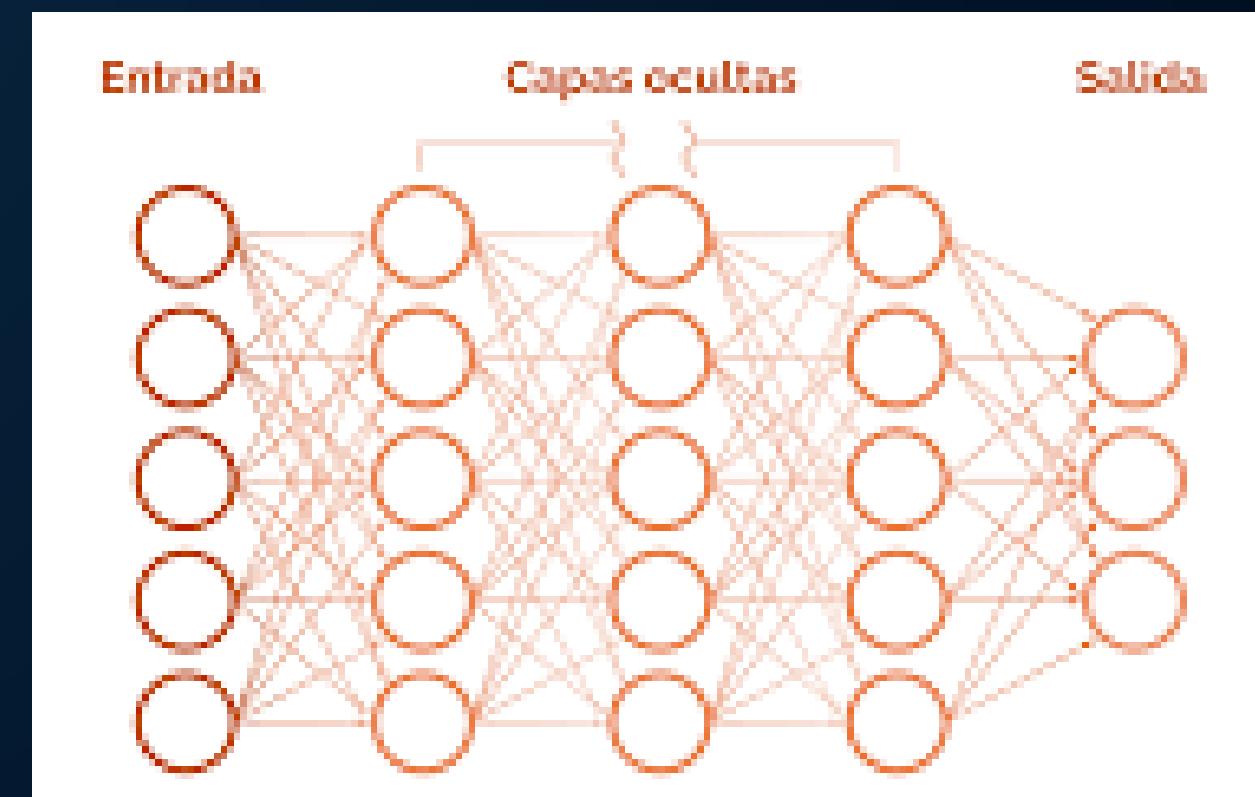
Random Forest



Support Vector Machines



Redes neuronales profundas



ML PARA SEÑALES MEDICAS

- ECG (Electrocardiograma)
- EEG (Electroencefalograma)
- Ritmo cardiaco
- Saturación de oxígeno
- Señales respiratorias

¿COMO FUNCIONA?

- 1: Se realiza un procesamiento de señales para extraer características (frecuencia, amplitud, variabilidad).
- 2: El ML identifica patrones anormales que indican enfermedades.
- 3: El modelo aprende señales reales con diagnósticos confirmados

APLICACIONES

- Determinar arritmias en ECG
- Predecir convulsiones con EEG
- Monitoreo de pacientes en tiempo real
- Diagnóstico de apnea del sueño

VENTAJAS

- Diagnóstico automáticos y continuos
- Alta sensibilidad ante cambios sutiles en señales
- Util en cuidados intensivos y monitoreo remoto

CASO REAL

En 2020, Google desarrolló un modelo de Deep Learning para analizar mamografías.

El sistema logró:

- Reducir falsos positivos en 5.7%
- Reducir falsos negativos en 9.4%
- Mejorar la precisión en comparación con radiólogos humanos

El modelo aprendió de más de 90,000 mamografías reales y ayudó a identificar cáncer en etapas más tempranas.

LIMITACIONES Y RIESGOS

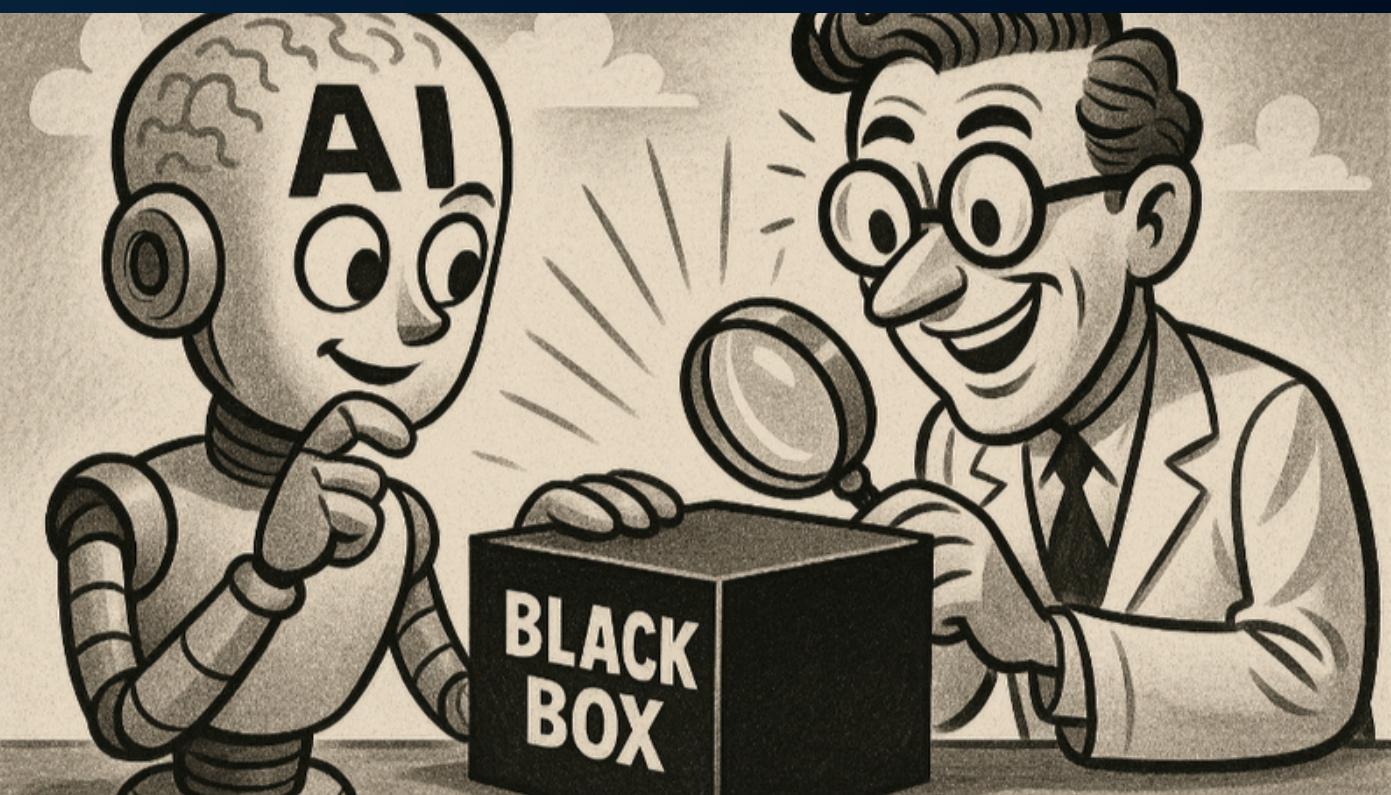
Aunque el Machine Learning ha demostrado resultados impresionantes en el diagnóstico médico, también presenta riesgos, limitaciones y desafíos importantes.

- **Falta de interpretabilidad (Caja negra)**

Muchos modelos de Deep Learning funcionan como una “caja negra”: no es fácil explicar por qué tomaron una decisión.

RIESGOS:

- Los médicos no pueden confiar plenamente en un sistema si no explica su razonamiento.
- Dificultad para detectar errores.



- Dificultad para detectar errores

Algunos medicos pueden confiar demasiado en la IA , lo que genera:

RIESGOS

- Menor juicio clinico.
 - Menor habilidad para detectar errores del sistema.
 - Problemas si el sistema falla o genera predicciones incorrectas.
-
- Datos insuficientes o de mala calidad

El ML necesita muchos datos limpios y bien etiquetados , pero la realidad es que :

- Los hospitales tienen datos incompletos
- Las etiquetas pueden tener errores.
- Los equipos usan diferentes formatos

REFERENCIAS

Sidey-Gibbons, J. A. M., & Sidey-Gibbons, C. J. (2019). Machine learning in medicine: A practical introduction. *BMC Medical Research Methodology*, 19(1), 64. <https://doi.org/10.1186/s12874-019-0681-4>

Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine learning in medicine. *New England Journal of Medicine*, 380(14), 1347-1358. <https://doi.org/10.1056/NEJMra1814259>

Topol, E. J. (2019). High-performance medicine: The convergence of human and artificial intelligence. *Nature Medicine*, 25(1), 44-56. <https://doi.org/10.1038/s41591-018-0300-7>

Sidey-Gibbons, J. A. M., & Sidey-Gibbons, C. J. (2019). Machine learning in medicine: A practical introduction. BMC Medical Research Methodology, 19(1), 64. https://doi.org/10.1186/s12874-019-0681-4

Lundervold, A. S., & Lundervold, A. (2019). An overview of deep learning in medical imaging focusing on MRI. *Zeitschrift für Medizinische Physik*, 29(2), 102-127. <https://doi.org/10.1016/j.zemedi.2018.11.002>

Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine learning in medicine. New England Journal of Medicine, 380(14), 1347-1358. https://doi.org/10.1056/NEJMra1814259

Acharya, U. R., Fujita, H., Lih, O. S., Adam, M., Tan, J. H., & Chua, C. K. (2017). Automated detection of arrhythmias using convolutional neural network. *Information Sciences*, 405, 81-90. https://doi.org/10.1016/j.ins.2017.04.012

McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., ... Suleyman, M. (2020). International evaluation of an AI system for breast cancer screening. *Nature*, 577, 89-94. https://doi.org/10.1038/s41586-019-1799-6